



Análisis de signos vitales mediante técnicas de visión por computadora

Autor:

Ing. Santiago Ruiz

Director:

Esp. Ing. Gerardo Alexis Vilcamiza Espinoza (FIUBA)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 24 de agosto de 2026 y el 18 de octubre de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar.	5
2. Identificación y análisis de los interesados	6
3. Propósito del proyecto	7
4. Alcance del proyecto	7
5. Supuestos del proyecto.	8
6. Requerimientos	8
7. Historias de usuarios (<i>Product backlog</i>).	9
8. Entregables principales del proyecto	10
9. Desglose del trabajo en tareas	10
10. Diagrama de Activity On Node.	11
11. Diagrama de Gantt	14
12. Presupuesto detallado del proyecto	16
13. Gestión de riesgos	16
14. Gestión de la calidad	18
15. Procesos de cierre	20

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	24 de agosto de 2026
1	Se completa hasta el punto 5 inclusive	6 de septiembre de 2026
2	Se completa hasta el punto 9 inclusive	13 de septiembre de 2026
3	Se completa hasta el punto 12 inclusive	20 de septiembre de 2026
4	Se completa el plan	27 de septiembre de 2026

Acta de constitución del proyecto

Buenos Aires, 24 de agosto de 2026

Por medio de la presente se acuerda con el Ing. Santiago Ruiz que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Análisis de signos vitales mediante técnicas de visión por computadora” y consistirá en la implementación de un sistema basado en técnicas de fotoplethysmografía remota (rPPG) capaz de estimar, de manera no invasiva, signos vitales de una persona como la frecuencia cardíaca. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo estimado de ARS 16.000.600, con fecha de inicio el 24 de agosto de 2026 y fecha de presentación pública en abril de 2027.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Médicos de atención remota
Prepagas que ofrecen telemedicina

Esp. Ing. Gerardo Alexis Vilcamiza Espinoza
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El monitoreo de signos vitales constituye una fuente de información fundamental para evaluar el estado de salud y bienestar de una persona. Entre estos signos, se encuentran la frecuencia cardíaca y la frecuencia respiratoria. Tradicionalmente, esta medición requiere sensores en contacto directo con la piel (electrodos, oxímetros de dedo, bandas pectorales), lo que limita su uso en escenarios en que el contacto físico es incómodo, poco práctico o directamente imposible. Un ejemplo de esta situación es una consulta de telemedicina, en la que el profesional de la salud no tiene contacto físico con su paciente y, por lo tanto, no puede recurrir al instrumental habitual de un consultorio presencial.

En los últimos años, la fotoplethysmografía remota (*remote photoplethysmography*, rPPG) surgió como una alternativa *contactless* que permite estimar signos vitales a partir de video. Esta técnica aprovecha las variaciones sutiles e imperceptibles al ojo humano en el color de la piel que produce el flujo sanguíneo sincronizado con el ciclo cardíaco. Los primeros trabajos en esta línea utilizaban técnicas clásicas de procesamiento de señales (separación ciega de fuentes, filtrado de color) para extraer esta información a partir de video facial. El avance del *deep learning* aplicado a visión por computadora amplió significativamente la robustez de estas técnicas frente a los métodos clásicos, con arquitecturas como DeepPhys (redes convolucionales con mecanismos de atención) o PhysNet (redes 3D espacio-temporales). A pesar de estos avances, todavía persisten desafíos relevantes: artefactos de movimiento, variaciones de iluminación, diferencias en el tono de piel y una brecha de rendimiento entre condiciones controladas de laboratorio y escenarios de uso reales.

Este proyecto surge como un trabajo individual de carácter exploratorio y aplicado, sin financiamiento externo ni acuerdos de confidencialidad asociados. La propuesta de valor del proyecto consiste en ofrecer una alternativa de bajo costo y sin fricción para obtener una estimación de signos vitales durante una consulta remota, dado que solo requiere una cámara. Esto habitualmente ya se encuentra disponible en el dispositivo que el paciente utiliza para acceder a la consulta. Se distingue de las soluciones basadas en sensores de contacto, que dependen de instrumental específico y no siempre está disponible fuera de un entorno clínico. El principal interesado en este tipo de solución es el profesional de la salud que realiza consultas de telemedicina, así como las plataformas que dan soporte a esta modalidad de atención, quienes valoran contar con información objetiva del paciente.

El proyecto se encuentra en una etapa de prueba de concepto. En esta, se busca validar la viabilidad técnica de estimar la frecuencia cardíaca a partir de video, y a partir de esa misma señal, obtener una estimación de la frecuencia respiratoria. Para ello, se comparará el desempeño de un enfoque clásico y uno basado en *deep learning* sobre datasets públicos reconocidos en la literatura de rPPG. Estos enfoques serán contrastados con mediciones de referencia obtenidas con sensores de contacto.

La solución propuesta toma como entrada un video del rostro de la persona capturado con una cámara convencional, y produce como salida una estimación numérica de la frecuencia cardíaca y respiratoria, que pueden contrastarse contra una medición de referencia. En la figura 1 se presenta el diagrama en bloques del sistema. Se observa que, en primer lugar, se realiza la detección facial y la selección de una región de interés (ROI) sobre el video de entrada. Luego, se extrae una única señal fisiológica (rPPG), ya sea mediante un pipeline clásico de procesamiento de imagen o mediante un modelo de *deep learning* de tipo espacio-temporal. A continuación, dicha señal se filtra en dos bandas de frecuencia distintas, a partir de las que se estiman la frecuencia cardíaca y la frecuencia respiratoria (mediante análisis espectral o directamente a la

salida del modelo). Finalmente, los valores estimados se comparan contra las mediciones de los sensores de referencia a los fines de validar el desempeño del sistema.




Figura 1. Diagrama en bloques del sistema.

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Médicos de atención remota	Prepagas que ofrecen telemedicina	-
Responsable	Ing. Santiago Ruiz	FIUBA	Alumno
Orientador	Esp. Ing. Gerardo Alexis Vilcamiza Espinoza	FIUBA	Director del Trabajo Final
Usuario final	-	Prepagas/Pacientes	Profesionales/Pacientes

A continuación se listan las principales características de cada interesado:

- Cliente: valora contar con información objetiva y no invasiva del estado fisiológico del paciente durante una consulta remota, en un contexto donde hoy no dispone de instrumental de medición.
- Orientador: colabora en la definición del alcance técnico del proyecto y en la validación de las decisiones metodológicas relacionadas con las técnicas de visión por computadora y *deep learning* aplicadas.
- Usuario final: el profesional de la salud valora la rapidez y la no invasividad de la medición, mientras que el paciente valora no depender de instrumental adicional ni de conocimientos técnicos para su uso.

3. Propósito del proyecto

El propósito de este proyecto es diseñar, implementar y evaluar un sistema basado en visión por computadora y *deep learning* capaz de estimar, de manera no invasiva y a partir de video facial, la frecuencia cardíaca y respiratoria de una persona. Se busca comparar su desempeño frente a mediciones de referencia obtenidas con sensores de contacto, de modo de sentar una base técnica que permita, en un futuro, incorporar esta capacidad a escenarios de telemedicina u otros contextos en los que la medición por contacto resulte poco práctica.

4. Alcance del proyecto

El proyecto incluye:

- Relevamiento del estado del arte en fotoplethismografía remota (rPPG), desde métodos clásicos hasta enfoques basados en *deep learning*.
- Implementación de un pipeline clásico (*baseline*) de extracción de señal rPPG: detección facial, selección de región de interés (ROI), extracción de señal de color, filtrado y estimación de la frecuencia cardíaca mediante análisis espectral.
- Implementación o adaptación de un modelo de *deep learning* (arquitectura de tipo CNN espacio-temporal) para la estimación de la frecuencia cardíaca a partir de video.
- Entrenamiento y validación del modelo utilizando datasets públicos reconocidos en la literatura de rPPG (UBFC-rPPG como dataset principal, PURE como dataset complementario).
- Comparación del desempeño del pipeline clásico y del modelo de *deep learning*, utilizando métricas estándar (error absoluto medio, raíz del error cuadrático medio, coeficiente de correlación de Pearson).
- Documentación de resultados, limitaciones del sistema y condiciones de uso válidas.

El presente proyecto no incluye:

- La estimación de otras variables fisiológicas de mayor complejidad, como la presión arterial o la saturación de oxígeno (SpO2).
- El desarrollo de una interfaz de usuario o de una integración con una plataforma de telemedicina real.
- La validación clínica del sistema con pacientes reales ni la obtención de aprobaciones regulatorias para su uso como dispositivo médico.
- El despliegue del sistema en un entorno de producción o su optimización para ejecución en tiempo real sobre hardware embebido.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- Los datasets públicos a utilizar (UBFC-rPPG, PURE) se encuentran disponibles y accesibles durante todo el desarrollo del proyecto.
- Se cuenta con el tiempo y los recursos de cómputo necesarios (incluyendo, de ser necesario, acceso a GPU) para entrenar y evaluar los modelos de *deep learning* propuestos.
- Las condiciones de captura de video consideradas (iluminación razonablemente estable, rostro visible y sin oclusiones significativas) son representativas de un escenario típico de videollamada o consulta de telemedicina.
- El alcance del proyecto se limita a una prueba de concepto técnica, por lo que no se requiere validación clínica ni cumplimiento de normativa sanitaria para su desarrollo.

6. Requerimientos

Los requerimientos se agrupan en cinco categorías: funcionales, de desempeño, de datos y validación, de documentación, y regulatorios/éticos.

1. Requerimientos funcionales

- 1.1. El sistema debe detectar el rostro de la persona en al menos el 95 % de los *frames* de un video con iluminación estable. (Prioridad: alta)
- 1.2. El sistema debe extraer una señal fisiológica (rPPG) a partir de la región de interés (ROI) facial detectada. (Prioridad: alta)
- 1.3. El sistema debe estimar la frecuencia cardíaca (HR) del sujeto, expresada en latidos por minuto (bpm). (Prioridad: alta)
- 1.4. El sistema debe estimar la frecuencia respiratoria (RR) del sujeto, expresada en respiraciones por minuto, a partir de la misma señal utilizada para estimar la HR. (Prioridad: alta)
- 1.5. El sistema debe implementar un *pipeline* clásico de estimación (sin *deep learning*) como línea base de comparación. (Prioridad: alta)
- 1.6. El sistema debe implementar al menos un modelo de *deep learning* de tipo espacio-temporal para la estimación de la HR. (Prioridad: alta)
- 1.7. El sistema debe poder procesar, en modo *offline*, videos provenientes de los datasets públicos seleccionados. (Prioridad: alta)
- 1.8. El sistema podrá, de forma opcional, procesar video capturado en vivo desde una cámara web con fines exploratorios. (Prioridad: baja, opcional)

2. Requerimientos de desempeño

- 2.1. La estimación de HR, tanto del *pipeline* clásico como del modelo de *deep learning*, debe alcanzar un error absoluto medio (MAE) no mayor a 5 bpm sobre el dataset UBFC-rPPG. (Prioridad: alta)

- 2.2. El coeficiente de correlación de Pearson entre la HR estimada y la HR de referencia debe ser mayor a 0,8 sobre el dataset UBFC-rPPG. (Prioridad: media)
- 2.3. El tiempo de procesamiento de un video de un minuto de duración, en modo *offline*, no debe superar los dos minutos sobre el hardware disponible para el proyecto. (Prioridad: baja)
3. Requerimientos de datos y validación
 - 3.1. El sistema debe evaluarse, como mínimo, sobre el dataset UBFC-rPPG. (Prioridad: alta)
 - 3.2. De contar con tiempo suficiente, el sistema debe evaluarse adicionalmente sobre el dataset PURE. (Prioridad: media, opcional)
 - 3.3. El conjunto de datos utilizado para entrenamiento y el de evaluación deben mantenerse disjuntos, sin superposición de sujetos. (Prioridad: alta)
4. Requerimientos de documentación
 - 4.1. Se debe documentar la arquitectura del *pipeline* clásico y del modelo de *deep learning* utilizados. (Prioridad: alta)
 - 4.2. Se deben documentar las métricas obtenidas y las condiciones bajo las que se obtuvieron. (Prioridad: alta)
 - 4.3. Se deben documentar las limitaciones identificadas del sistema y sus condiciones de uso válidas. (Prioridad: media)
5. Requerimientos regulatorios y éticos
 - 5.1. El proyecto debe utilizar exclusivamente datasets públicos que cuenten con consentimiento informado de los sujetos y licencia de uso académico o de investigación. (Prioridad: alta)
 - 5.2. El sistema no debe presentarse ni utilizarse como un dispositivo médico certificado, dado que no cuenta con validación clínica ni aprobación regulatoria. (Prioridad: alta)

7. Historias de usuarios (*Product backlog*)

Los *story points* de cada historia se calculan como la suma de tres subpuntajes, cada uno en una escala de 1 a 5: complejidad, dificultad e incertidumbre. El valor del *story point* debe pertenecer siempre a la sucesión de Fibonacci.

1. “Como investigador, quiero implementar la detección facial y la selección de la región de interés (ROI) sobre un video, para poder aislar la zona de piel relevante para la estimación de la señal fisiológica.”
Story points: 5 (complejidad: 2, dificultad: 2, incertidumbre: 1)
2. “Como investigador, quiero extraer la señal rPPG mediante un *pipeline* clásico de procesamiento de imagen, para contar con una línea base de comparación.”
Story points: 8 (complejidad: 3, dificultad: 3, incertidumbre: 2)
3. “Como investigador, quiero estimar la frecuencia cardíaca a partir de la señal rPPG mediante análisis espectral, para validar la viabilidad del enfoque clásico.”
Story points: 5 (complejidad: 2, dificultad: 2, incertidumbre: 1)

4. “Como investigador, quiero estimar la frecuencia respiratoria a partir de la misma señal rPPG utilizada para la frecuencia cardíaca, para evaluar la viabilidad de obtener ambas variables sin duplicar el *pipeline* de captura.”
Story points: 5 (complejidad: 2, dificultad: 1, incertidumbre: 2)
5. “Como investigador, quiero implementar o adaptar un modelo de *deep learning* de tipo espacio-temporal, para estimar la frecuencia cardíaca directamente a partir del video.”
Story points: 13 (complejidad: 5, dificultad: 4, incertidumbre: 4)
6. “Como investigador, quiero entrenar el modelo de *deep learning* sobre el dataset UBFC-rPPG, para contar con un modelo ajustado a datos reales de referencia.”
Story points: 8 (complejidad: 3, dificultad: 3, incertidumbre: 2)
7. “Como investigador, quiero calcular las métricas de error (MAE, RMSE, correlación de Pearson) entre las estimaciones y las mediciones de referencia, para poder comparar objetivamente ambos enfoques.”
Story points: 5 (complejidad: 2, dificultad: 2, incertidumbre: 1)
8. “Como investigador, quiero documentar los resultados obtenidos y las limitaciones identificadas, para dejar registro de las condiciones de uso válidas del sistema.”
Story points: 3 (complejidad: 1, dificultad: 1, incertidumbre: 1)
9. “Como profesional de la salud, quiero que el sistema entregue una estimación numérica clara de la frecuencia cardíaca y respiratoria, para poder interpretarla rápidamente en una demostración del sistema.”
Story points: 5 (complejidad: 2, dificultad: 2, incertidumbre: 1)

8. Entregables principales del proyecto

Los entregables del proyecto son:

- Código fuente del *pipeline* clásico de estimación de frecuencia cardíaca y respiratoria.
- Código fuente y pesos entrenados del modelo de *deep learning*.
- Script de evaluación y comparación de métricas (MAE, RMSE, correlación de Pearson) entre ambos enfoques.
- Reporte de resultados, con las limitaciones identificadas y las condiciones de uso válidas del sistema.
- Memoria del trabajo final.
- Presentación para la defensa pública del trabajo.

9. Desglose del trabajo en tareas

1. Relevamiento y diseño (60 h)
 - 1.1. Revisión del estado del arte en rPPG (20 h)

- 1.2. Selección y descarga de datasets públicos (10 h)
- 1.3. Definición de la arquitectura del *pipeline* clásico y del modelo de *deep learning* (20 h)
- 1.4. Definición de las métricas de evaluación (10 h)
2. Implementación del *pipeline* clásico (120 h)
 - 2.1. Implementación de la detección facial y selección de ROI (30 h)
 - 2.2. Implementación de la extracción de la señal rPPG (30 h)
 - 2.3. Implementación del filtrado y la estimación espectral de la HR (30 h)
 - 2.4. Implementación del filtrado y la estimación espectral de la RR (30 h)
3. Implementación y entrenamiento del modelo de *deep learning* (180 h)
 - 3.1. Preprocesamiento de datos para el entrenamiento (30 h)
 - 3.2. Implementación de la arquitectura del modelo (40 h)
 - 3.3. Entrenamiento del modelo (40 h)
 - 3.4. Ajuste de hiperparámetros (40 h)
 - 3.5. Validación del modelo sobre el conjunto de test (30 h)
4. Evaluación y comparación de enfoques (100 h)
 - 4.1. Cálculo de métricas de error (MAE, RMSE) (30 h)
 - 4.2. Cálculo del coeficiente de correlación de Pearson (20 h)
 - 4.3. Análisis comparativo entre el *pipeline* clásico y el modelo de *deep learning* (30 h)
 - 4.4. Identificación de limitaciones y condiciones de uso válidas (20 h)
5. Documentación y cierre (140 h)
 - 5.1. Redacción de la primera versión de la memoria del trabajo final (30 h)
 - 5.2. Revisión y correcciones sugeridas por el director (40 h)
 - 5.3. Redacción de la versión final de la memoria (30 h)
 - 5.4. Preparación de la presentación para la defensa pública (20 h)
 - 5.5. Ensayo de la defensa pública (20 h)

Cantidad total de horas: 600 h.

10. Diagrama de Activity On Node

El diagrama de Activity on Node (AoN) se construye a partir de las 22 subtarefas del desglose del trabajo (WBS) definido en la sección anterior, tomando horas como unidad de tiempo. Se identificaron relaciones de precedencia que permiten ejecutar ciertas tareas en paralelo. Esto es razonable incluso cuando se trata de un proyecto ejecutado por una única persona, dado que el entrenamiento del modelo de *deep learning* insume tiempo de cómputo en GPU durante el que se puede avanzar con otras tareas independientes, como la implementación del *pipeline* clásico. Bajo este criterio, se definieron bifurcaciones paralelas en distintos puntos del proyecto.

En la figura 2 se presenta el diagrama en bloques. Se observa que el camino crítico del proyecto, resaltado en rojo, atraviesa específicamente la rama del modelo de *deep learning*. Dicha secuencia es la siguiente: 1.1 → 1.3 → 3.1 → 3.2 → 3.3 → 3.4 → 3.5 → 4.1 → 4.3 → 4.4 → 5.1 → 5.2 → 5.3 → 5.5. Esto se debe a que dicha rama insume más tiempo que la implementación del *pipeline* clásico, que queda con una holgura considerable y podría demorarse sin afectar la fecha de finalización del proyecto.




Figura 2. Diagrama de *Activity on Node*.

11. Diagrama de Gantt

El diagrama de Gantt se elaboró a partir de las fechas de inicio y finalización de cada una de las cinco actividades del WBS. Estas se calcularon en función de la duración obtenida en el diagrama de *Activity on Node* y de la fecha de inicio del proyecto (24 de agosto de 2026). Se incluyen, además, dos hitos: la entrega de la versión final de la memoria al director y la defensa pública del trabajo.

En la figura 3 se presenta el diagrama de Gantt correspondiente.




Figura 3. Diagrama de Gantt del proyecto.

12. Presupuesto detallado del proyecto

El presupuesto se expresa en dólares estadounidenses (USD), dado que constituye una referencia más estable para valorizar las horas de trabajo profesional. Se indica la equivalencia en pesos argentinos (ARS) tomando la cotización del dólar oficial del Banco de la Nación Argentina (BNA) del 25 de septiembre de 2026, de \$1.545 ARS por dólar (valor de venta).

Los costos directos corresponden a la valorización de las 600 horas de trabajo estimadas en la sección 9, a una tarifa de referencia de USD 17 por hora para un perfil de ingeniería con especialización en inteligencia artificial. Los costos indirectos incluyen la amortización proporcional del equipo (notebook) utilizado durante el desarrollo y la conectividad a internet. Cabe destacar que las principales herramientas de software utilizadas (Python, PyTorch, OpenCV, MediaPipe) son de código abierto y no representan un costo adicional.

COSTOS DIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
Horas de trabajo del responsable del proyecto	600 h	USD 17,00	USD 10.200,00
SUBTOTAL COSTOS DIRECTOS			USD 10.200,00
COSTOS INDIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
Amortización de notebook personal	1	USD 100,00	USD 100,00
Conectividad a internet	1	USD 90,00	USD 90,00
SUBTOTAL COSTOS INDIRECTOS			USD 190,00
TOTAL			USD 10.390,00

El monto total estimado equivale, a la cotización de referencia indicada, a aproximadamente ARS 16.052.550.

13. Gestión de riesgos

a) Identificación de los riesgos y estimación de sus consecuencias. La severidad (S) y la probabilidad de ocurrencia (O) se califican de 1 a 10.

Riesgo 1: el modelo de *deep learning* no generaliza a condiciones fuera de laboratorio.

- Severidad (S): 7. La brecha de rendimiento entre condiciones controladas y escenarios reales está ampliamente documentada en la literatura de rPPG (ver Sección 1). Si se concretara, el sistema podría no cumplir el requerimiento de $M4E \leq 5\%$ (Sección 6) fuera del dataset de evaluación.
- Probabilidad de ocurrencia (O): 6. Es un riesgo conocido y frecuente en esta técnica, y más al tratarse de una primera implementación sin optimización extensiva.

Riesgo 2: carencia o degradación del acceso a GPU en la nube durante el entrenamiento.

- Severidad (S): 6. Afectaría directamente el grupo 3 del WBS (Implementación y entrenamiento del modelo de *deep learning*), que se encuentra en el camino crítico del proyecto (Sección 10).

- Probabilidad de ocurrencia (O): 6. El nivel gratuito de plataformas como Google Colab tiene límites de uso y cortes de sesión variables y no garantizados.

Riesgo 3: atraso en el cronograma por tratarse de un único responsable.

- Severidad (S): 8. Al no existir un equipo que permita redistribuir tareas, cualquier atraso en una actividad del camino crítico impacta directamente en la fecha de finalización del proyecto.
- Probabilidad de ocurrencia (O): 5. El autor combina el desarrollo del proyecto con otras actividades laborales y académicas, lo que hace probable alguna semana de menor dedicación.

Riesgo 4: calidad o representatividad insuficiente de los datasets públicos utilizados.

- Severidad (S): 6. Una baja diversidad de sujetos o tonos de piel en UBFC-rPPG y PURE podría afectar la validez de las métricas obtenidas y la generalización del modelo.
- Probabilidad de ocurrencia (O): 4. Ambos datasets son ampliamente utilizados y validados en la literatura de rPPG (Sección 1), lo que reduce este riesgo.

Riesgo 5: dificultad para comparar el *pipeline* clásico y el modelo de *deep learning* bajo las mismas condiciones.

- Severidad (S): 5. De no definirse un protocolo de evaluación común, la comparación entre ambos enfoques (Sección 3) perdería validez.
- Probabilidad de ocurrencia (O): 4. Es un riesgo moderado, mitigable con una adecuada planificación desde el inicio del proyecto (Sección 6, requerimientos de datos y validación).

b) Tabla de gestión de riesgos ($RPN = S \times O$):

Riesgo	S	O	RPN	S*	O*	RPN*
R1. El modelo de DL no generaliza fuera de laboratorio	7	6	42	7	3	21
R2. Indisponibilidad de GPU en la nube	6	6	36	6	3	18
R3. Atraso de cronograma (único responsable)	8	5	40	8	3	24
R4. Calidad/representatividad de los datasets	6	4	24	-	-	-
R5. Comparación no homogénea entre enfoques	5	4	20	-	-	-

Criterio adoptado: se tomarán medidas de mitigación obligatorias en los riesgos cuyo RPN sea mayor o igual a 35 (R1, R2 y R3). Los valores marcados con (*) corresponden a la estimación luego de aplicar la mitigación.

c) Plan de mitigación de los riesgos que exceden el umbral

R1 (RPN 42 $\rightarrow$ RPN* 21). Se aplicará aumento de datos (*data augmentation*) sobre variaciones de brillo, contraste y ruido durante el entrenamiento del modelo. Se documentarán explícitamente las condiciones de uso válidas del sistema (Sección 6, requerimientos de documentación). De ser posible, se validará adicionalmente con una pequeña captura propia en condiciones distintas a las del dataset de entrenamiento. Esto no reduce la severidad del

riesgo en caso de ocurrir ($S^*=7$), pero sí su probabilidad ($O^*=3$), al mitigar preventivamente sus causas más frecuentes.

R2 (RPN 36 $\rightarrow$ RPN* 18). Se utilizarán *checkpoints* periódicos durante el entrenamiento del modelo para poder reanudarlo sin pérdida de avance ante un corte de sesión. Se evaluará reducir el tamaño de *batch* o del modelo si la disponibilidad de GPU se ve restringida. Esto reduce la probabilidad de impacto real sobre el cronograma ($O^*=3$).

R3 (RPN 40 $\rightarrow$ RPN* 24). El cronograma (Sección 11) ya contempla una holgura considerable entre la finalización del trabajo técnico y la fecha de defensa pública. Esto funciona como margen de contingencia ante atrasos. Adicionalmente, se establecerán hitos intermedios verificables semanalmente y se priorizarán las tareas identificadas sobre el camino crítico (Sección 10) frente a las que cuentan con holgura. Esto reduce la probabilidad de que un atraso actual comprometa la fecha final ($O^*=3$), aunque la severidad de un atraso mayor sigue siendo alta ($S^*=8$).

14. Gestión de la calidad

A continuación se seleccionan doce requerimientos de la Sección 6, considerados críticos por su impacto directo en el cumplimiento del propósito del proyecto, y se detallan para cada uno las acciones de verificación (caja blanca) y de validación (caja negra).

- **Detección facial en al menos el 95 % de los *frames* con iluminación estable.**
 - Verificación: se ejecuta el detector sobre el conjunto de videos de UBFC-rPPG y se calcula automáticamente el porcentaje de *frames* con detección exitosa.
 - Validación: se revisan junto con el director muestras de video con la detección superpuesta, confirmando que el criterio se cumple de forma consistente.
- **Extracción de una señal fisiológica (rPPG) a partir de la ROI facial.**
 - Verificación: se inspecciona visualmente la señal extraída, confirmando que exhibe una componente periódica compatible con el pulso cardíaco observado.
 - Validación: se contrasta la periodicidad observada con la frecuencia cardíaca de referencia del dataset, sin discrepancias evidentes.
- **Estimación de la frecuencia cardíaca (HR).**
 - Verificación: se calcula el MAE y el RMSE entre la HR estimada y la de referencia sobre el conjunto de evaluación.
 - Validación: se presentan al director los resultados junto con ejemplos de estimaciones individuales, confirmando su razonabilidad clínica (valores dentro de rangos fisiológicos plausibles).
- **Estimación de la frecuencia respiratoria (RR) a partir de la misma señal utilizada para la HR.**
 - Verificación: se calcula el error de la RR estimada contra una referencia disponible y se confirma que no se haya duplicado el *pipeline* de captura.
 - Validación: se revisa con el director si el enfoque de derivar la RR de la misma señal rPPG resulta metodológicamente aceptable para el alcance del trabajo.

■ **Implementación de un *pipeline* clásico como línea base.**

- Verificación: pruebas unitarias sobre cada etapa del *pipeline* (detección, ROI, filtrado, estimación espectral).
- Validación: el director revisa que el *pipeline* sea reproducible de punta a punta con un comando o script único.

■ **Implementación de un modelo de *deep learning* espacio-temporal.**

- Verificación: se confirma que el modelo entrena sin errores y que su arquitectura corresponde a lo documentado (Sección 6, requerimientos de documentación).
- Validación: el director revisa el código y la arquitectura, confirmando su correspondencia con el estado del arte relevado en la Sección 1.

■ **MAE de HR no mayor a 5 bpm sobre UBFC-rPPG.**

- Verificación: cálculo automático del MAE sobre el conjunto de evaluación completo, para ambos enfoques.
- Validación: el director revisa el resultado junto con el análisis comparativo de la Sección 9 (grupo 4), aceptando el cumplimiento del umbral.

■ **Coefficiente de correlación de Pearson mayor a 0,8 sobre UBFC-rPPG.**

- Verificación: cálculo automático del coeficiente sobre el conjunto de evaluación completo.
- Validación: el director revisa el resultado y su consistencia con el MAE obtenido para el mismo enfoque.

■ **Evaluación sobre, como mínimo, el dataset UBFC-rPPG.**

- Verificación: se confirma que el reporte de resultados incluye métricas calculadas sobre la totalidad de los sujetos del dataset.
- Validación: el director confirma que no se hayan excluido sujetos sin justificación documentada.

■ **Conjuntos de entrenamiento y evaluación disjuntos, sin superposición de sujetos.**

- Verificación: se inspecciona el *script* de partición de datos, confirmando de forma automática la ausencia de sujetos compartidos entre conjuntos.
- Validación: el director revisa el criterio de partición utilizado y su justificación metodológica.

■ **Documentación de la arquitectura de ambos enfoques y de las métricas obtenidas.**

- Verificación: se revisa que la memoria del trabajo final incluya el detalle completo de ambas arquitecturas y de las condiciones de prueba.
- Validación: el director confirma que la documentación es suficiente para que un tercero pueda reproducir el trabajo.

■ **Uso exclusivo de datasets públicos con consentimiento informado y licencia académica.**

- Verificación: se revisan los términos de licencia y uso de UBFC-rPPG y PURE, **confirmando** su compatibilidad con un uso académico y no comercial.
- validación: el director confirma que no existen objeciones éticas ni regulatorias sobre las fuentes de datos utilizadas.

Las acciones de verificación descriptas se automatizan, en la medida de lo posible, mediante *scripts* de cálculo de métricas. Las acciones de validación en su mayoría se revisarán con el director.

15. Procesos de cierre

Se establece el siguiente procedimiento para la reunión final de evaluación del proyecto, con el objetivo de verificar el cumplimiento del plan, cerrar administrativamente el trabajo y dejar registro de las lecciones aprendidas.

Participantes convocados: el **Responsable** (autor), el **Orientador** (director del **Trabajo Final**) y, en la instancia de defensa pública, los jurados evaluadores designados.

Preparación previa. El Responsable **congela** el repositorio del proyecto con una etiqueta de versión final, **reúne** los entregables definidos en la **Sección** 8 y **compila** la evidencia necesaria para la reunión. Esta evidencia tendrá los resultados de las métricas de calidad (**Sección** 14), cronograma planificado versus ejecutado (**Secciones** 10 y 11), presupuesto ejecutado versus el presupuesto de la **Sección** 12, y el estado final de los riesgos identificados en la **Sección** 13. El **Orientador** **revisa** esta documentación con antelación y **envía** comentarios.

a) Pautas para analizar si se respetó el Plan de Proyecto original. El **Responsable** **presenta** la comparación y el **Orientador** la **revisa**, siguiendo el siguiente procedimiento:

- Alcance: se **contrasta** lo efectivamente implementado contra lo definido en la **Sección** 4, indicando si algún punto del alcance no se cumplió y su justificación.
- Cronograma: se compara la duración planificada en el diagrama de Gantt (**Sección** 11) contra las fechas reales de cada grupo del WBS, **documentando** las causas de los desvíos, en caso de existir.
- Presupuesto: se compara el costo ejecutado contra el presupuesto detallado en la **Sección** 12, **expresando** la variación en USD y en términos porcentuales.
- Calidad: se revisa el cumplimiento de los requerimientos críticos identificados en la **Sección** 14, en base a los resultados de verificación y validación obtenidos.

Como resultado de este análisis, se labra una breve acta de evaluación del plan, **indicando** si el proyecto cumple, cumple parcialmente o no cumple con lo planificado, junto con los desvíos justificados.

b) Identificación de técnicas y procedimientos útiles e inútiles, problemas y soluciones. El Responsable registra esta información en un informe de lecciones aprendidas, utilizando una retrospectiva estructurada (qué continuar, qué dejar de hacer, qué empezar a hacer) sobre los principales hitos del proyecto (selección de arquitectura, entrenamiento del modelo, comparación de enfoques). El Orientador participa de esta instancia aportando su

perspectiva sobre el proceso de trabajo conjunto. El informe queda documentado junto con la memoria del trabajo final, como antecedente para futuros trabajos relacionados dentro del área.

c) Organización del acto de agradecimiento. El Responsable organiza un breve reconocimiento dirigido al Orientador por su acompañamiento durante el proyecto, en forma de una nota de agradecimiento y un intercambio informal posterior a la defensa pública. Al tratarse de un trabajo individual sin financiamiento externo, este agradecimiento no representa un gasto adicional a los ya contemplados en la Sección 12, y se realiza dentro de los 14 días posteriores a la defensa pública.

Cierre administrativo. Finalmente, se archivan los entregables definidos en la Sección 8 junto con la memoria final del trabajo, y se procede a la entrega formal de la documentación al Orientador y a la carrera, dando por concluido el proyecto.